Instituto Tecnológico y de Estudios Superiores de Monterrey

Departamento de computación

Inteligencia Artificial avanzada para la ciencia de datos

Grupo 101

Módulo 2 Uso de framework o biblioteca de aprendizaje máquina para la implementación de una solución.

Luis Ignacio Ferro Salinas

A01378248

12 de septiembre de 2022

Al usar un framework para implementar mi red neuronal, tengo más hiperparámetros disponibles para variar. Usaré la misma técnica de dejar todos los hiperparámetros constantes excepto el que estoy estudiando para ver el efecto de su cambio sobre las métricas.

En este caso realizo un modelo para predecir si una persona va a sobrevivir el choque del Titanic o no dependiendo de algunas de sus características.

Hiperparámetros:

- Arquitectura del modelo (numero de capas intermedias)
- Batch size
- Epochs
- Funciones de activación intermedias

Arquitectura del modelo

- batch_size=256,
- epochs=100,
- funciones de activación intermedias=sigmoid

Una sola neurona (regresión logística) 9 x 1

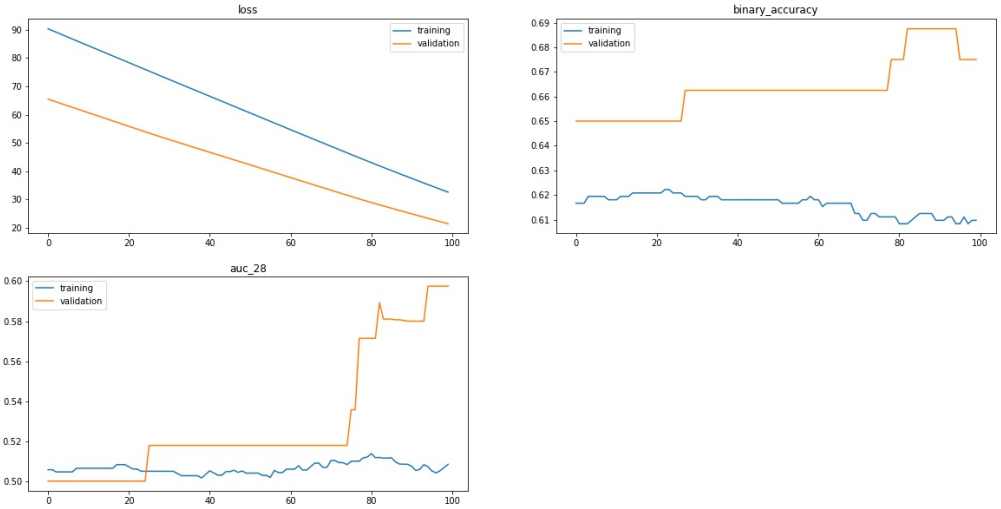

En este caso se ve que están un poco separadas las métricas de entrenamiento y de validación, pero parece que van en la misma dirección. Todas las métricas tienen mejora al final de las epochs contra al inicio.

Una capa intermedia 9 x 16 x 1

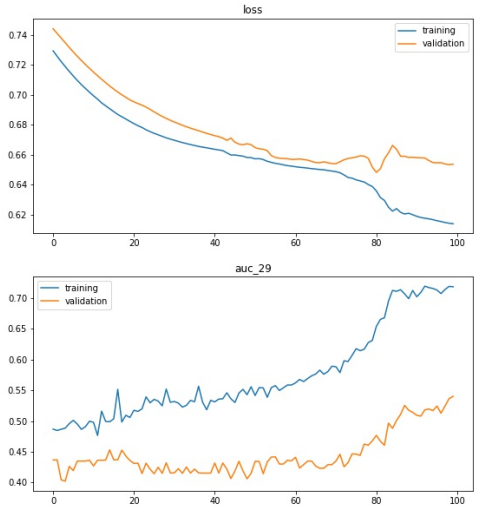

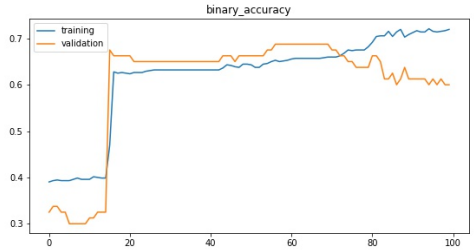

En este caso, las métricas de pérdida y de accuracy van bastante juntas, pero la AUC se separa bastante. Las métricas tienen mejores valores que en el caso anterior. Todas las métricas mejoran al final de las epochs contra el inicio.

2 capas intermedias 9 x 32 x 8 x 1

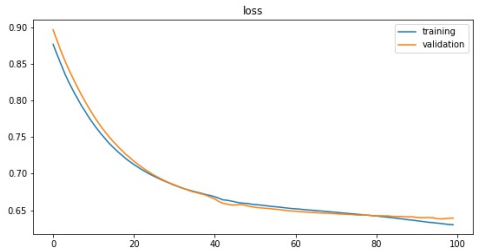

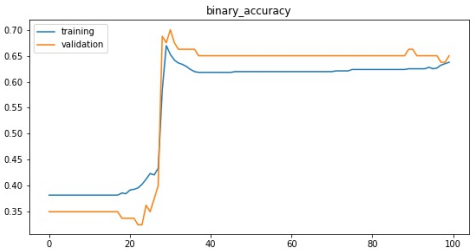

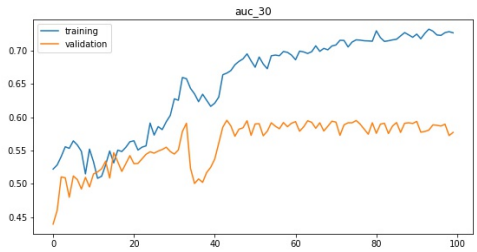

Parece que en este caso van bastante juntas las métricas de validación y training, excepto en la AUC. Las métricas tienen valores similiares contra la arquitectura anterior.

Batch_size
- Arquitectura 9 x 16 x 1
- Epochs 100
- Funciones de activación intermedias sigmoid

Batch_size 800 (todas las muestras de entrenamiento)

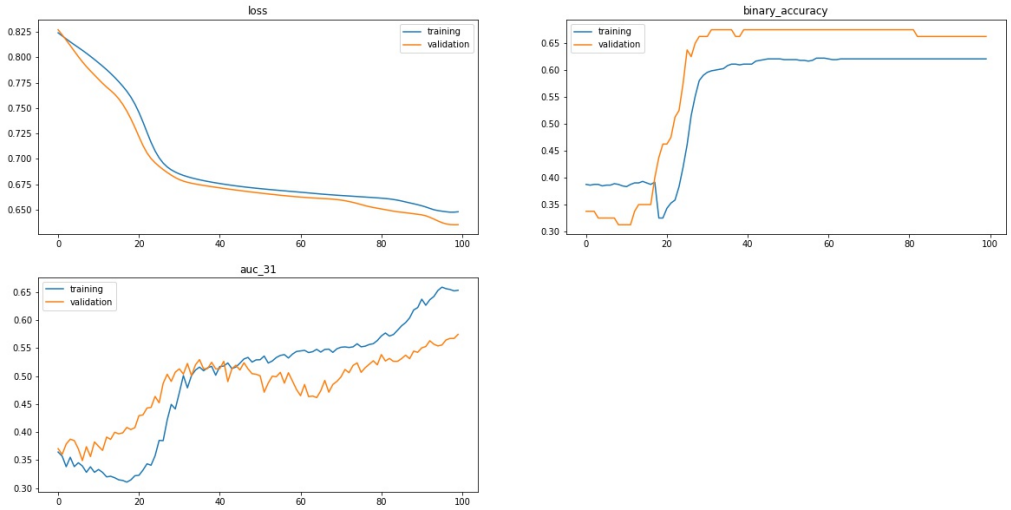

Parece que la métrica de AUC se separa un poco entre training y validation, no hubo gran cambio en los valores de las métricas contra 256 muestras, ahora pruebo 64 muestras.

Batch_size 64

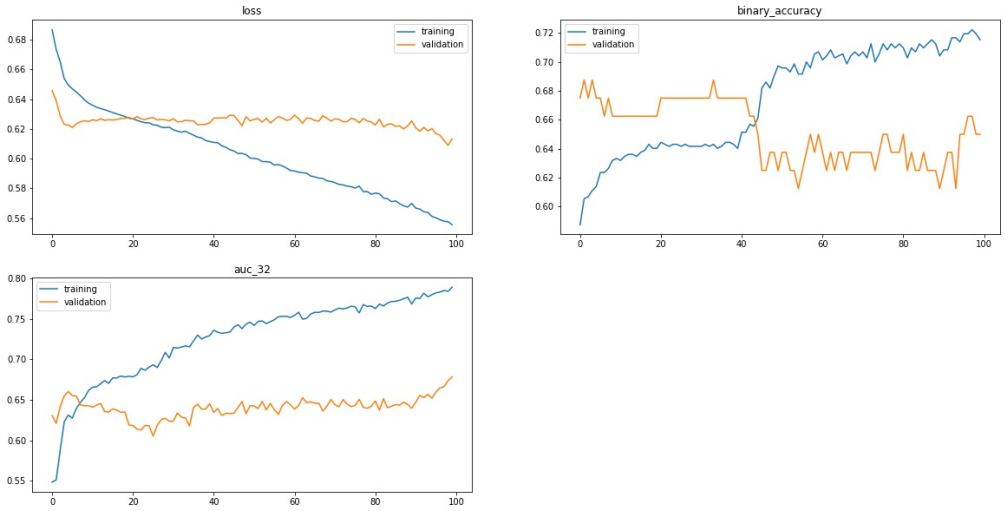

En este caso ya vemos bastante diferencia entre la forma en que cambian las métricas a través de las epochs entre validation y training, posiblemente 64 muestras en este caso no son suficientes para guiar el descenso del gradiente de la mejor manera.

Epochs

Arquitectura del modelo 9 x 16 x 1
Batch size 256
Funciones de activación intermedias sigmoid

1000 epochs

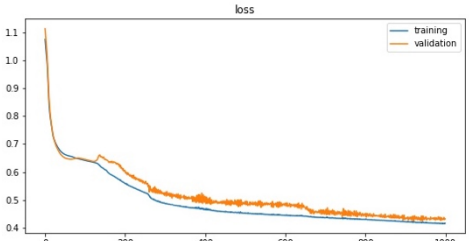

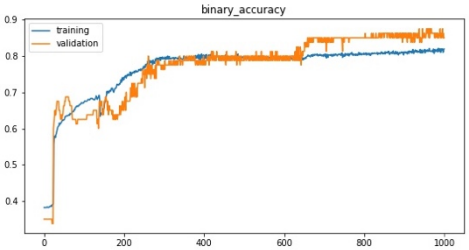

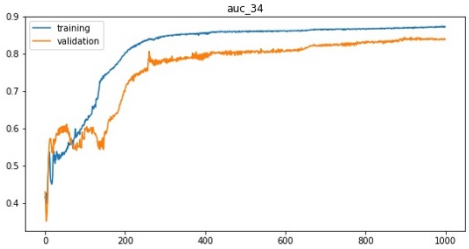

Estas métricas se ven bastante bien a través de las 1000 epochs, porque tenemos un crecimiento recíproco entre validation y training, ósea en general crecen las métricas en ambos casos de training y de validation. Parece también que se comienzan a estabilizar las métricas, ya no cambian tanto al final.

Funciones de activación intermedias

- Arquitectura del modelo 9 x 16 x 1
- Batch size 256
- Epochs 1000

Funciones de activación intermedias ReLU

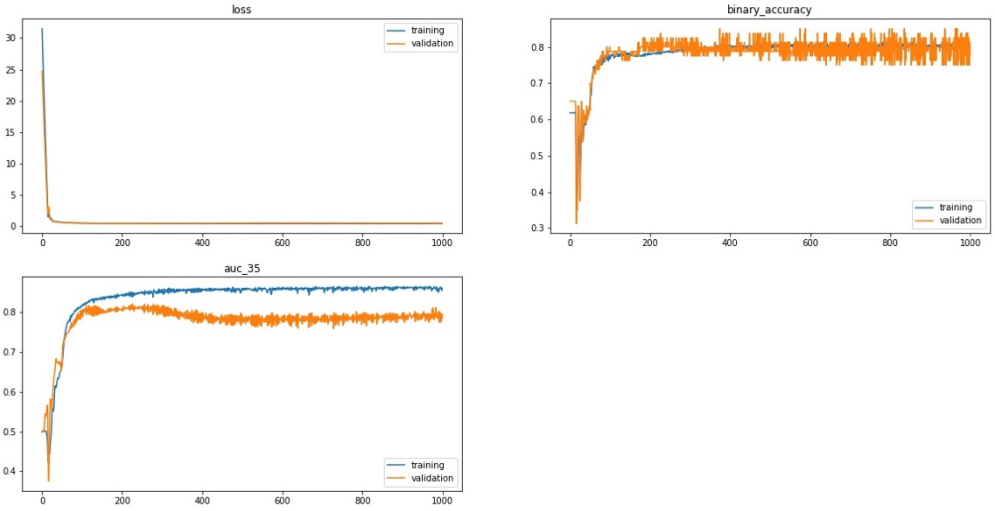

WOW, esto está interesante porque ahora la pérdida en el training y validation convirgió extremadamente más rápido que con la función intermedia de sigmoid.

Funciones de activación intermedia tanh

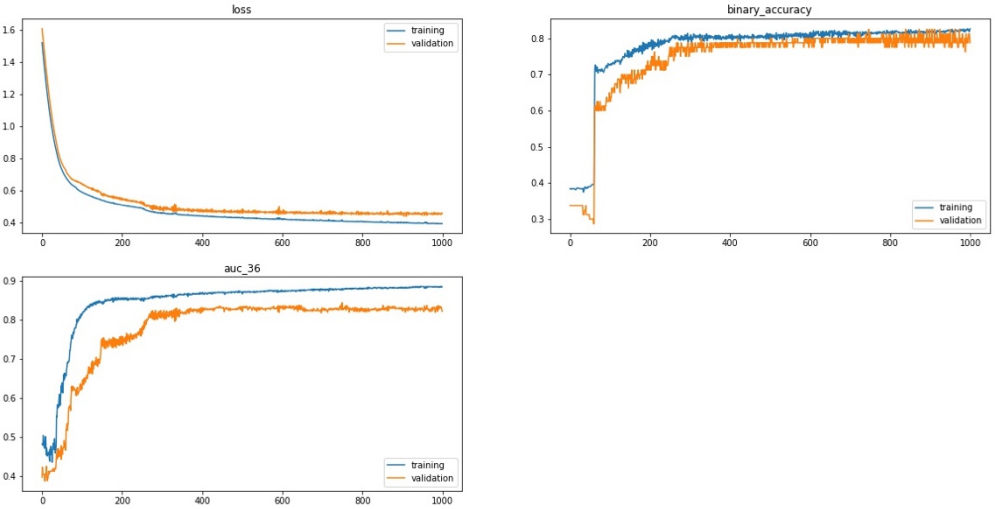

Es un resultado similar al de ReLU, pero creo que el comportamiento de ReLU es tan bueno en la loss que puedo bajar significativamente el número de epochs

Configuración final

- Arquitectura del modelo 9 x 16 x 1
- Batch size 256
- Epochs 300

Funciones de activación intermedias ReLU

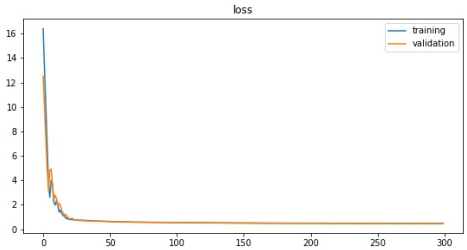

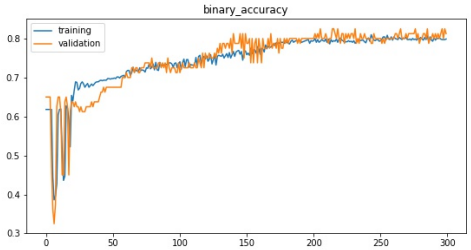

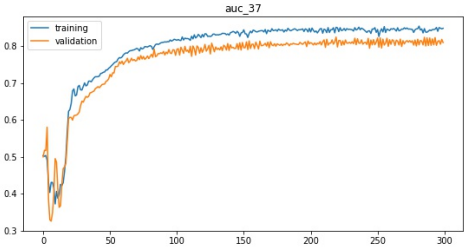

Ahora vuelvo a hacer el Split de training y testing con conjuntos distintos a ver si este comportamiento es reproducible

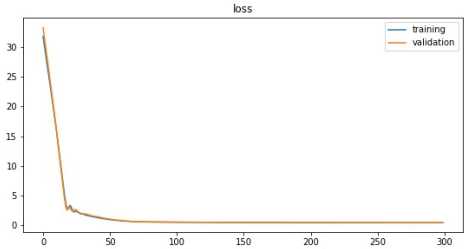

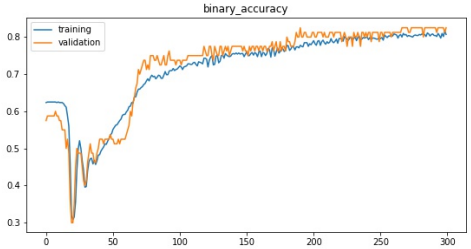

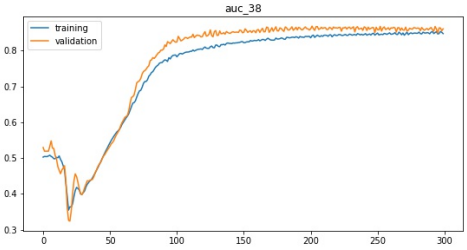

Y los resultados son bastante similares aún con conjuntos de training y testing diferentes.

Ahora vuelvo a hacer el proceso anterior pero ahora plasmando los valores finales de las métricas en tablas para visualizarlo en un espacio más reducido

Arquitectura	Perdida final	Perdida final validacion	Accuracy final	Accuracy final validación	AUC final	AUC final valifación
9x1	48.616893 76831055	45.798728 942871094	0.6138888 597488403	0.625	0.5272565 484046936	0.5026332 73601532
9x16x1	0.6185844 540596008	0.6147946 715354919	0.6277777 552604675	0.625	0.7423335 909843445	0.7297563 552856445
9x32x8x1	0.6177414 059638977	0.6066555 976867676	0.6277777 552604675	0.6374999 88079071	0.7405641 674995422	0.7679394 483566284

Batch size	Perdida final	Perdida final validacion	Accuracy final	Accuracy final validación	AUC final	AUC final valifación
800	.62526941 29943848	0.6237276 792526245	0.6347222 328186035	0.6499999 761581421	0.75624191 76101685	0.74358129 50134277
64	0.5504095 554351807	0.5367115 73600769	0.7180555 462837219	0.7749999 761581421	0.7886120 080947876	0.787030 93528747 56

Epochs	Perdida final	Perdida final validacion	Accuracy final	Accuracy final validación	AUC final	AUC final valifación
1000	0.3927774131298065	0.3862328529 35791	0.8277778029441833	0.875	0.3862328529 35791	0.8512178659439087

Activación de capa intermedia	Perdida final	Perdida final validacion	Accuracy final	Accuracy final validación	AUC final	AUC final valifación
ReLU	0.4429752 826690674	0.4084412 157535553	0.8013888 597488403	is 0.8500000 238418579	0.8548538 684844971	0.8459512 591362
Tanh	0.4262090 921401977 5	0.4198582 768440246 6	0.8180555 701255798	0.8625000 11920929	0.8606981 039047241	0.8439762 592315674

Configuración final	Perdida final	Perdida final validacion	Accuracy final	Accuracy final validación	AUC final	AUC final valifación
	0.4454258084297178	0.41798406839370734	0.7875000238418579	0.8374999761581421	0.8569480776786804	0.8535220026969691

Predicciones
Hago 89 predicciones sobre las 89 muestras de test que el modelo nunca ha visto y parece que sigue bastante bien a lo que debió haber predicho.

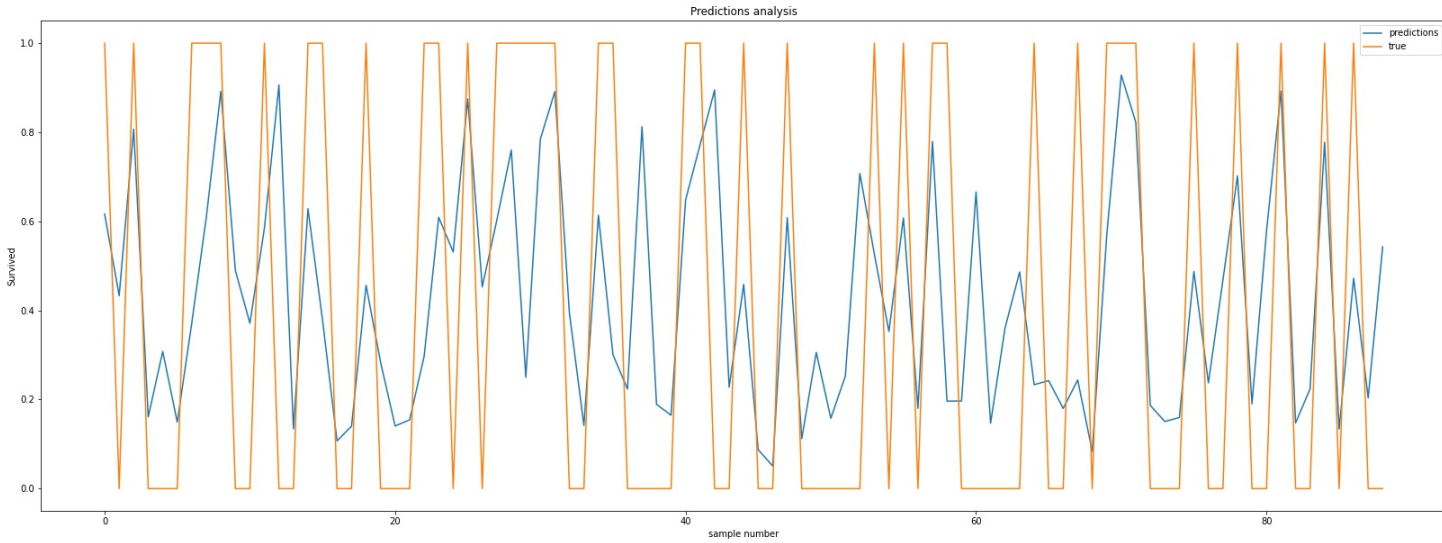

Conclusión final

En esta ocasión logré la implementación inicial en muy poco tiempo comparado con la realización del modelo sin framework, pero me tardé más recopilando los resultados y variando los hiperparámetros, ya que el framework me da muchas más opciones de personalización y tuneo del modelo. Ahora con la capacidad de incluir las métricas de Accuracy y de AUC pude visualizar un poco mejor el desempeño de mi modelo de clasificación binaria, y fue interesante que cuando logré mejoras en el desempeño en general todas las métricas mejoraban así tenía más seguridad de que en verdad mejoró mi modelo.

Algo muy importante fue que pude visualizar el desempeño de mi modelo con un conjunto de validación, porque así pude ver que en algunas combinaciones de hiperparámetros, mi modelo comenzaba a mejorar en métricas solamente para el conjunto de entrenamiento y no para el conjunto de validación, lo que me ayudó a detectar un posible overfitting y evitarlo.